

הוכחה ש $\ker(A^T)$ הוא подпространство

$$1) \text{ נוכיח } (\lambda u + \mu v) \in \ker(A^T)$$

נוכיח. נניח $\lambda u + \mu v \in \ker(A^T)$.

$$xv = 0 \quad \Leftrightarrow \quad \lambda u + \mu v \in \ker(A^T)$$

$$\Rightarrow \lambda u + \mu v \in \ker(A)$$

$$(x^T x)v = x^T(xv) = x^T 0 = 0$$

$$\ker(x) \subseteq \ker(x^T x) \quad \text{בגלות } v \in \ker(x^T x) \quad \Leftarrow$$

$$\Leftarrow \text{ נסמן } v = \lambda u + \mu v \in \ker(A^T)$$

$$(x^T x)(\lambda u + \mu v) = x^T(xv) = 0$$

הכל כיוון ש $xv = 0$ $\Rightarrow x^T 0 = 0$ כי $x \neq 0_m$,

$$\ker(x^T x) \subseteq \ker(x) \subseteq \ker(A)$$

$$\ker(x) = \ker(x^T x)$$

2)

\square

$$\text{הוכחה. נוכיח } A^T \perp \ker(A) \quad \text{בגלות}$$

$$\text{הypothesis: } y \in \ker(A) \quad x \in \ker(A^T)$$

$$\langle x, y \rangle = 0$$

הypothesis. $y \in \ker(A) \Rightarrow Ay = 0$

$$6) \text{ נוכיח } x = A^T u \quad \text{בגלות } x \in \ker(A) \quad \Leftarrow$$

$$x^T y = x^T A^T u = (Ax)^T u$$

$Ax = 0$ if and only if $x \in \text{ker}(A)$

$$(Ax)^T u = 0 \Leftrightarrow$$

$$\text{Im } A^T \subseteq \text{ker}(A)^\perp \text{ by } \text{def} \Leftrightarrow$$

$$z \in \text{Im } A^T \perp \text{ means } z^T u = 0 \Leftrightarrow$$

$$z^T u = 0$$

$$= z^T (A^T u) = (Az)^T u = 0 \Leftrightarrow$$

$$\Leftrightarrow z \in \text{ker } A \text{ by def} \Leftrightarrow$$

$$\text{Im } (A^T)^\perp \subseteq \text{ker } A \Leftrightarrow$$

$$\text{Im } (A^T) \subseteq \text{ker } (A)^\perp \Leftrightarrow$$

$$\text{Im } (A^T) = \text{ker } (A)^\perp \text{ by def} \Leftrightarrow$$

Now we want to show that $y = xu$ is in $\text{ker } (A^T)$.
Since $x \in \text{ker } A$, we have $x^T u = 0$.

$y \in \text{ker } (A^T)$ since $y^T u = x^T u = 0$.

Therefore $y \in \text{ker } (A^T)$ if and only if $y = xu$.

Now we want to show that $y \in \text{ker } (A^T)$ if and only if $y \in \text{ker } (x^T)$.
Since $y = xu$, we have $y^T u = x^T u = 0$.

$y \in \text{ker } (A^T) \Leftrightarrow y^T u = 0 \Leftrightarrow x^T u = 0 \Leftrightarrow x \in \text{ker } (x^T) \Leftrightarrow y \in \text{ker } (x^T)$

$$\Leftrightarrow y \perp \text{ker}(x^T)$$

□

ההוכחה מושגת על ידי הוכחה של $x^T x = 0$ מילוקי, כלומר $x^T x = 0$ מילוקי $y \in \text{ker}(x^T)$.

ההוכחה מושגת על ידי הוכחה של $x^T x = 0$ מילוקי $y \in \text{ker}(x^T)$.

$$\text{ker}(x^T x) = \text{ker}(x)$$

$$v \in \text{ker}(x) \Leftrightarrow v \in \text{ker}(x^T x) \quad \text{מכיון}$$

$$v \perp \text{ker}(x) \quad \text{מכיון}$$

לפיכך $v \in \text{ker}(x)$ מילוקי $x^T x = 0$ מילוקי $x^T v = 0$.

$x^T x = 0$ מילוקי $x^T v = 0$ מילוקי $v \in \text{ker}(x^T x)$.

לפיכך $v \in \text{ker}(x)$ מילוקי $x^T v = 0$ מילוקי $v \in \text{ker}(x)$.

□

לע' ש ρ מוגדר כ $\rho = \sum_{i=1}^k v_i \otimes v_i^*$ אם v_1, \dots, v_k הם מושגים של ρ ו- $\rho = \sum_{i=1}^k v_i \otimes v_i^*$. אז $v_i \otimes v_i^*$ הוא מושג של ρ אם ורק אם $v_i \otimes v_i^*$ מוגדר כ $\rho = \sum_{i=1}^k v_i \otimes v_i^*$.

$$\rho_{ij} = \sum_{t=1}^k v_{i,t} \cdot v_{j,t}$$

ככל ש $v_{i,t}$ מוגדר כ $v_i \otimes v_t$, כלומר $v_i \otimes v_t$ מוגדר כ $\rho = \sum_{i=1}^k v_i \otimes v_i^*$.

$\rho_{i,j} = \rho_{j,i}$ כי $v_i \otimes v_t = v_t \otimes v_i$.

הו מושג ρ ית

בנוסף ל- ρ מוגדר ρ' על ידי $\rho'_{ij} = \rho_{i,j} - \rho_{i,i} - \rho_{j,j} + \rho_{i,i} \rho_{j,j}$.
 ρ' מוגדר כ $\rho' = \sum_{i=1}^k v_i \otimes v_i^*$.

$U = \text{Span}(v_{k+1}, \dots, v_d)$, $V = \text{Span}(v_1, \dots, v_k)$.

הו מושג ρ' מוגדר על ידי $\rho' = U \otimes V^*$ במשמעות $U \otimes V^*$ של מושג $U \otimes V$.

$$\rho_{ik} = \rho_{ik} - \rho_{ii} - \rho_{kk}$$

$$\rho_{ik} = \sum_{i=1}^k v_i v_i^T \cdot u \Rightarrow u = k, v_1 + \dots + v_k$$

$$\Rightarrow \sum_{i=1}^k v_i \sum_{j=1}^k v_j^T \cdot d_j \cdot v_j = \sum_{i=1}^k v_i \cdot \sum_{j=1}^k d_j \cdot v_j^T =$$

$$= \sum_{i=1}^k k_i v_i = u$$

ו今, $P_u = u$ \Rightarrow P_u הוא מושג בפ' \Leftrightarrow
 $\lambda = 1$

$$P_u = \sum_{i=1}^k v_i v_i^T \sum_{j=k+1}^d \beta_j u_j = 0 \Rightarrow \lambda = 0$$

↗ $v_i \in U$ $i > k$
 ↗ $\beta_j \neq 0$ $j > k$

לעתה נשים $U = V \oplus W$ ו P_u הוא מושג בפ' \Leftrightarrow
 $\lambda = 0$ $\Leftrightarrow P_u \in W$

$P_V = V \cup W$ בסיסי $\{v_1, \dots, v_k\}$ ב- V ו- $\{w_1, \dots, w_d\}$ ב- W \Rightarrow $P_V = V$ \Leftrightarrow (III)

$$P^2 = P \cdot P = \sum_{i=1}^k v_i v_i^T \sum_{j=1}^k v_j v_j^T = \quad (\text{IV})$$

$$= \sum_{i=1}^k \sum_{j=1}^k v_i v_i^T v_j v_j^T = \sum_{i=1}^k \sum_{j=1}^k v_i \delta_{ij} v_j v_j^T =$$

↗ $v_i \in V$ $v_j \in W$
 ↗ $\delta_{ij} = 1$ $i = j$

סדרה
 $P \cdot P = P$

$$= \sum_{i=1}^k v_i v_i^T = P$$

$$(I - P)P = IP - P \cdot P = \quad \Rightarrow \underline{P \cdot P} \quad (\text{V})$$

$$P \cdot P = 0 \quad \text{ובו } P = P^2 \Rightarrow I - P = P \quad \Rightarrow \quad (I - P)P = 0$$

$$x^T x \in \text{הכל } \Rightarrow \text{ מינימום}$$

$$\underline{\underline{x^T x}} \in \text{הכל } \Rightarrow \underline{\underline{(x^T x)^{-1}}}$$

$$\underline{\underline{U^T = (x^T x)^{-1} x^T y}}$$

בנוסף למשתנה x ישנו מושג x^+ שקיים $\forall y \in \mathbb{R}^n$ $\exists x \in \mathbb{R}^m$ כך ש- x מקיים $x^T x \cdot y = x^+ \cdot y$

$$x = U \Sigma V^T$$

$$x^+ = V \Sigma^+ U^T$$

בנוסף למשתנה x ישנו מושג $x^T x \cdot y = x^+ \cdot y$ כ- x^+ מקיים $\Sigma^+ = \Sigma^{-T}$ ו- $\sigma_i \neq 0$

$$x^T x = (U \Sigma V^T)^T (U \Sigma V^T) =$$

$$= V \Sigma^T U^T U \Sigma V^T = V \Sigma^2 V^T$$

בנוסף למשתנה x ישנו מושג $x^T x \cdot y = x^+ \cdot y$

$$(x^T x)^{-1} = V (\Sigma^2)^{-1} V^T$$

$$(x^T x)^{-1} x^T = V (\Sigma^2)^{-1} V^T V \Sigma U^T =$$

$$= V (\Sigma^2)^{-1} \Sigma U^T$$

$$(\Sigma^2)^{-1} = \begin{pmatrix} \frac{1}{\sigma_1^2} & & \\ & \ddots & \\ & & \frac{1}{\sigma_d^2} \end{pmatrix} \quad \text{מוגדר}$$

$$\text{לפיכך שיטת } \Sigma^{-1} \text{ מוגדר כ-} (\Sigma^2)^{-1} = \Sigma^{-1}$$

$$(\Sigma^2)^{-1} \Sigma = \begin{pmatrix} \frac{1}{\sigma_1^2} & & \\ & \ddots & \\ & & \frac{1}{\sigma_n^2} \end{pmatrix} = \Sigma^{-1}$$

$$= \Sigma^+$$

$$(\lambda^T x)^{-1} x^T = V \Sigma^+ u^T = x^+ \quad \Leftarrow$$

מבחן בדוק
 $x^T x$ מוגדר כ- $\sum \sigma_i^2$ ו- $x^+ = \underbrace{\Sigma^+ u^T}_{\in \mathbb{R}^n}$

$\text{Span}(x_1, \dots, x_m) = \mathbb{R}^d$ אם ורק אם $x^T x \neq 0$ (ז"
 אם ורק אם x לא ניצב)
 $\text{Span}(x_1, \dots, x_m)$ מוגדרת כ-
 $\{x^T v \mid v \in \mathbb{R}^m\}$ ו-
 $x^T x \neq 0$ מוגדרת כ-
 $\text{rank}(x) = d$ (בנוסף
 ל- $x^T x \neq 0$ יש d מושגים
 ייחודיים b_1, \dots, b_d ש-
 $x^T b_i = 1$ ו-
 $x^T b_j = 0$ עבור כל $j \neq i$)

$$\text{מכאן } x^T x \Rightarrow \text{rank}(x^T x) = d = \text{rank}(x) \Leftarrow$$

$$\text{מכאן } x^T x \Rightarrow \text{rank}(x^T x) = d = \text{rank}(x) \Leftarrow$$

$$x^T x \Rightarrow \text{rank}(x^T x) = d = \text{rank}(x) \Leftarrow$$

הוכחה!

הנורמליזציה מושגת על ידי $\bar{u} = u + \bar{x}$
 $\|\bar{u}\| \leq \|u\|$

דוגמא: מתקיים $\|\bar{u}\| \leq \|u\|$ כי \bar{u} מוגדר כ $\bar{u} = u - \bar{x}$.
 כלומר, \bar{u} מוגדר כ $\bar{u} = u - \text{הORTHOGONAL PROJECTION}$ של u על $\text{sp}(x)$.

$$\Sigma = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & 0 \end{pmatrix}, \Sigma = \text{diag}(\sigma_1, \dots, \sigma_d)$$

לפ' כי ניתן להציג \bar{u} כ $\bar{u} = \sum_{i=1}^d \bar{u}_i e_i$,
 כאשר \bar{u}_i מוגדר $\bar{u}_i = \langle \bar{u}, e_i \rangle e_i$, e_i מוגדר $e_i = \frac{x}{\|x\|}$,
 $\bar{u}_i = \bar{u} - \sum_{j \neq i} \bar{u}_j e_j$.

$\bar{u}_i = \bar{u}_i e_i$ כי e_i מוגדר כ $e_i = \frac{x}{\|x\|}$.

$$\|\bar{u}\|^2 = \sum_{i=1}^{d+1} \bar{u}_i^2 \quad \text{לפ' כי } \bar{u}_{d+1} = 0.$$

$$= \sum_{i=1}^r \bar{u}_i^2 + \sum_{i=r+1}^{d+1} \bar{u}_i^2 \geq \sum_{i=1}^r \bar{u}_i^2 + 0 = \sum_{i=1}^r \bar{u}_i^2 = \|\bar{u}\|^2$$

לפ' כי $\bar{u}_i = \bar{u} - \sum_{j \neq i} \bar{u}_j e_j$

$$\boxed{\|\bar{u}\| \geq \|\bar{u}'\|}$$

Fitting A Linear Regression Model

1. ראשית נרצה לבנות את הפונקציה `loadData()` אשר תבצע תהליך קדם-עיבוד למידע שקיבלנו עבור הבתים. אצינו באילו פיצרים השתמש, על איזו החלטתי לוותר ואיזה עיבוד בוצע.

- **שדות שלא נעשה בהם שימוש : *id, Date*** אלו שדות שנעודו ליצור סדר בתוך בסיס הנתונים שקיבלנו – לא רק שאינם קטגורים הם אינם נתונים לנו כל מידע כלל על הנכס ולכן אינם רלוונטיים כלל למודל הליניארי שלנו.

כמו כן, החלטתי כמו כן להעתלם מעמודות **קשירות למקומות** – בעולם האמתי למקומות הנכס יש חשיבות גבוהה מאוד ולכן אלו שדות שנרצה מאוד שיישפיעו על המודל שלנו, אך במקרה זה בו אין לנו ידועים את המקום או הקשר הספציפי שלו לשינוי הנכס אי הכנסתו לשקלול לא עוללה להשפיע הרבה על יכולת החיזוי של המודל שלנו (ניתן לדוגמא למצע את המקום ולהסתכל על המרחק בין הנקודות, אך שוב אין זה נותן אינדיקציה).

שים קוד 5, אך זו דגימה לא תקינה (20671) וلن אתמודד עם מקרים אלו בעיבוד שנבעץ בהמשך.

שדות 15 `sqft_living` ו- `sqft_lot`, מעבר על המידע שהתקבל, נראה כי שדות אלו רגילים לגודל המרתף או השטח העליון אם זה קיים. לעיתים מתקיים קשר ישיר ולפעמים יש תנודות במידע שלא ניתן להבין מהו הקשר. מכיוון שאנו משתמשים בכל שאר השדות, החלטתי לוותר על חישוב זה ולהתחשב במדדיה המקורי, כאשר הגדים האחרים שמסופקים לנו ישפיעו על המודל באופן זהה.

- **שדות שנלקחו כפי שהם :** מספר החדרים, קומות, מספר חדרי השירותים דירוגים כאלו ואחרים שימושיים (כמו מצב, ציון ונוף) אלו שdots שכנהה יתרהו יחסית בצורה טובה את הקשר הליניארי בניהם לבין *the response* שלנו – המחיר. לכן, לא נעבד אותם ונשתמש בהם כפי שקיבלו במודול.

• **שדות שדרושים עיבוד :** נשים לב כי ישנים שדות, כגון שנת שיפוץ וגודל מרתף, אשר מתארים מאורע אם קרה ואם לא מופיע 0. נרצה להימנע ממקרה זה מכיוון שהניל ייצור לנו רעש גבוה בדגימות שלנו מה שיופיע על יכולת חיזוי המודל. לכן, נדרש לחושב על כללי עיבוד שייעזרו לנו להחליט מה לעשות במקרה :

i. **שנת השיפוץ** – נייצר משתנה *Demolished* אשר קיבל ערכים {0,1}, כאשר 1 מצביע על כך שהיתה שיפוץ ו-0 על כך שלא היה.

ii. **גודל המרתף** – כדי להקטין את הפיזור ניתן שוב להגדיר משתנה מסווג עם קיומו של מתרף, אך נוכל לחלק את הגודל ב-1000, ולהקטין משמעותית את הפיזור בעת חישוב המודל כך נוכל בכל זאת להתחשב במקרים בהם יש מרתף ממש גדול. חשבתי לבצע מהלך זה מכיוון שלאחר שבעצתי ממוצע לעמודה, מתקבל כי הממוצע הינו 291.482 רגל מרובע, ולכן חלוקה ב-1000 תשמר אותנו יחסית קרובים ל-0 אך בכל זאת תייצר את ההבדל שהקטן שהוא רוצים עבור קיום המרתף. **נשים לב** כי זהו לא המצב בגודל השטח העליון וכן לא נשנה שדה זה, כאשר ה-0 היחיד שם הינו טעות במידע.

iii. **שנת בניה** – נרצה להמיר את שנת הבניה לגיל הנכס כאשר ככל שהנכס יותר

חדש כך קיבל ערך גובהה יותר, קרי $\frac{1}{2022 - age}$ תוק וידאו שאין אלו מחלקים מ-0

(לא בוצעה בדיקתי כי בדקתי במידע כי זה לא יתכן).


.2. נתבונן בשני פיצ'רים מתוך מטريقת הדגימות שלנו. נבחר את עמודת sqft_above – waterfront. מכיוון שהמודל שלנו מחפש קשר ליניארי, ניתן לראות כי שדות בהם יש קשר ליניארי כלשהו (כמו גודל מול מחיר) הינם שדות שיועילו יותר למודל שלנו מאשר שדות ביןארים, כגון יש/אין מרחת.

מתאים פירסון שהישבנו נותנים לנו את עצמת הקשר הליניארי בין Y, X (חיובי, שלילי או לא קיים).


ניתן לראות זאת ברור שנטכל על הפלטים שהזינו בחישוב של המתאם לכל פיצ'ר.

עבור הפיצ'רים שנבחרו מתתקבל:

sqft_above - Pearson Correlation is 0.6056177332802692



waterfront - Pearson Correlation is 0.26629523409982625



נשים לב כי הערכה שלנו נcona ובאמת המתאים עומדת מול מה שציפינו, עבור פיצ'ר גודל השיטה


- העליו, נקבל כי המתאים גובהה יותר – זאת גם בהתאם למגמה הכללית שאנו רואים בגרף, ביחס

מתאים נמוך עבור פיצ'ר ביניاري שלא מגלם כל קשר לינארי.

לכן, ניתן לראות כי באמצעות שדה `waterfront` פחות וועל למודל שלנו מכיוון שהוא לא תורם למציאת הקשר הلينארי, זאת ביחס לחברו נוכח בשדה השיטה.

3. הפונקציה המתאימה מומשה בקבצים
4. מצב גוף הפלט עבור שאלה זו.

RSS per train data percentage - Linear regression



נתבונן בגרף הפלט, באופן ישיר אנו רואים ככל שאנו מאמנים את המודל שלנו על יותר מידע, כך שהשגיאה מתכנסת וקטנה לדיקן המודל, שגיאה ריבועית של כ- 56 מיליארד, שאליו נוציא שורש נקבל כי השגיאה MSE הינה ~230 אלף דולר בהערכת מחיר בית עבור מידע שעוד לא נראה לפני.

מכיוון שלא הגדרנו מהי הטעות שאנואפשרים למודל להשיג, מבחינתו זה נתון נוסף שנitinן ללמידה ממנו ובהמשך לשנות אולאי את פרמטרי עיבוד המידע שלנו, או לנסות לשנות פיצרים נוספים ע"מ לקבל אומד טוב יותר, אם זה אפשרי – תוק ניסיון להימנע מלבעט overfit, כאשר כפי שציפינו שימוש בכל סט האימון הקטין את השגיאה וצמצם את מרחב הבחירה של המודל.


כמו כן, מבחינת confidence interval – ראיינו בהרצתה כי זה נתון שמאפשר לנו להמחיש את השונות, כאשר אנו יכולים ללמידה מן הפלט כי תחום זה הולך ומצטמצם ככל שאחו עולה, קרי מתקיים כי היכולת של המודל לחזות עבור \hat{y} ערכים גדולים ורחוקים יותר מצטמצם משמעותית, מה שמאפשר לנו לשפר את הדיקון, תחת סט האימון שקיבלו, אך במחיר של גמישות במודל (אותו תשלום שראיינו בין ה- $bias-variance$).

Polynomial Fitting


1. מומש בקבצים.
- 2.

a. מצ"ב גרף הפלט של הסעיף המבוקש. ניתן לראות כי הגרף מייצג מגמה כללית של פולינום מדרגה 3 או 4, על בסיס העיקול וירידה בגודל השיפוע כאשר הערכים מתרכבים ל-0.

Q2.1 - Temp to DayOfYear Israel



d. להלן גרף המייצג את סטיית התקן ביחס לחודשים כפי שהתבקשנו לעשוות




כפי שניתן לראות בגרף, אנו יכולים להעריך כי המודל שלנו לא יוכל לבצע פרדיקציה זהה על כל החודשים, מכיוון שסטיות התקן משתנות. ראיינו כי סטיית התקן והשונות הן המדד לנו להבין את פזרת המידע ולבן כ"כ שאלות גבויים יותר אנו למדדים כי המידע שיקבלנו יותר

מפוזר ולכון יהיה יותר קשה לקבל פרדיקציה טובה עבור מודלים שמתבססים על רגסיה ליניארית.

לכן, לפי תובנה זו ניתן לראות כי המודל שלנו יתנסה לבצע חיזוי מדויק בחודשי החורף ביחס לחודשי הקיץ – תובנה הגיונית עבור המעלות בישראל, כאשר ישן שניים עם שינויים גדולים בחורף ביחס לקיץ שהמעלות בו יחסית זרות.

3. להלן הפלט הנדרש :

Polyfit Q3




בהתבסס על גרפ זה ניתן לראות כי לא לכל המדינות הדפוס זהה, לדוגמה דרום אפריקה הפוכה לישראל, ירדן או הולנד (דבר הגיוני שהוא רוצים לראות מכיוון שהוא הצד השני של קו המשווה). לכן, ניתן לראות כי אילו נתונים מודול עבור ישראל בלבד, בהסתברות גבוהה מאוד שהמודל יספק פרדיקציה טובה מאוד עבור ירדן – ניתן לראות כי תוך התחשבות בסטיות התקון, קיימת חיפוי רבה בין ממוצעים ולכון הגיוני כי המודל יאפשר לקבל התאמה טובה גם במקרה זה.

מנגד, המודל לא יעבוד טוב כלל עבור דרום אפריקה מכיוון שסט האימון עבورو לא רלוונטי כלל. הניל מתנהג בצורה שונה ועל כן לא נוכל להתבסס – שזו סה"כ תובנה שציפינו לה.

עבור הולנד נשים לב כי הפונקציה בצורתה דומה מאוד לפונקציה שמיוצרת ע"י הממוצעים של ישראל אך קיים פער בין התוצאות. לכן מודול של ישראל כנראה יסגה להשיג פרדיקציה טובה עבור הולנד, אך אילו נצליח לנормל את הקבוע שמספריד בין הפונקציות נוכל לבצע ההתאמה ולקבל מודל שחוזה בצורה טובה.

4. להלן גրף הפלט שמסכם את שגיאות המודל תחת כל דרגה


Q4 polyfit - Model MSE pre degree



ניתן לראות כי פולינום מדרגה 5 השיג את השגיאה הקטנה ביותר, כאשר דרגה 4 מאוד קרובה בשגיאתה. פולינום מדרגה מאוד גבוהה כבר לא מושגים קירוב מתאים. נשים לב כי לא נרצה להמשיך ולהגדיל את דרגות הפולינום מכיוון שהוא נקבע overfit לסט האימון שלנו – ולכן נשאף להשתמש בפולינום מדרגה 4 או 5 כפונקציית הבדיקה שלנו עבור המקורה הנוכחי.

5. להלן פלט שגיאות המודל, כאשר התאמנו פולינום מדרגה 5 על כל המידע שהגיע מישראל

Q5 polyfit - Israel_Model MSE for other countries, k=5



ניתן לראות כי מה שציפינו בשאלת 3 בהחלט מתקיים, המודל הצליח לחזות יחסית בצורה טובה את הטמפרטורה עבור ירדן, אך השגיאה הריבועית עלתה בצורה משמעותית כאשר ניסינו לחזות את עברו דרום אפריקה והולנד.

ניתן גם להסביר מדוע השגיאה מדרום אפריקה אפילה קטנה יותר מזו של הולנד למרות שראינו שהגרפים של ישראל והולנד היו דומים – שגיאה זו עלתה בהפרש הטמפרטורה, אומנם עונות השנה הפוכות בין ישראל לדרום אפריקה, אך באופן ממוצע ראיינו כי הטמפרטורות יחסית קרובות, ביחס להולנד. لكن המודל השיג תוצאות שבאופן כללי קרובות יותר למידע עליו הוא אומן – וכך השגיאה במקרה זה קטנה יותר.

אילו היינו רוצים, ניתן היה להוסיף התערבות נוספת ולנرمל את תוצאות המודל במרקם הממוצע בין הטמפרטורות ולקבל חיזוי שכח"נ משמעותית טוב יותר עבור הולנד מן המודל הנוכחי.