

ר כ י ג רכז - ג רכז ג רכז ג רכז

208648154 ८८. फू.

Geometria

$$\text{arg min}_{v \in \mathbb{R}^n} \frac{1}{2} v^T Q v + c^T v, \quad A v \leq d$$

כברם: ערך נסיגת מילון וארון

$$\|u\|^2 = u^T I u = \gamma_2 u^T I u + \sigma.$$

$$= 2 \frac{\omega^T I \omega}{n} + \sigma^T \omega$$

অসমীয়া সংস্কৃত পৰি দেখুন আৰু বিশ্বাস কৰুন যে বৰ্তমানে

$$V = \mathbf{c}, Q = 2I,$$

$$c_e = \sigma_n$$

כ- כרמל מ- כרמל מ- כרמל מ- כרמל מ-

$$b_i \cdot \gamma_i \cdot (\langle u, z_i \rangle + 6) \geq \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$$

ב גראן מוקדש ב' x ב' מוקדש ב' x' ב' גראן כב' ב' מוקדש.

$$y_i(\langle x_i, \omega \rangle + b) = y_i(\langle x'_i, \omega \rangle) =$$

$$= y_i \underline{x'_i}^T \omega \geq 1$$

כדי שיאן יתגלו א' כי (בנוסף למשתנה
המיוצג על ידי b) א' יתגלו מתקיימת
הטלה $y_i x'_i$ מ-א' ב-א' (בנוסף למשתנה
המיוצג על ידי b)

• ערך פיקו ז' על גראן

$$Z = \left(-y_i x'_i - \right) \begin{matrix} \text{ט' מוקדש} \\ \text{ט' מוקדש} \\ \text{(בנוסף למשתנה)} \end{matrix}$$

• גראן ז' $\neq 0$ מ-ז' גראן פיקו

$$\text{לפ' ז' } Z = \left(y_i x'_i \right)$$

• כ-ז' פיקו, ז' על גראן מוקדש מוקדש

$$Z = \begin{pmatrix} 1 \\ \vdots \\ i \end{pmatrix} \quad \text{לפ' ז'}$$

• גראן פיקו, גראן מוקדש מוקדש פיקו גראן ז'
• מוקדש (-1) \rightarrow גראן ז'

$$-Z \in \begin{pmatrix} -1 & \\ & \ddots \\ & & -1 \end{pmatrix}$$
$$J = \begin{pmatrix} -1 & \\ & \ddots \\ & & -1 \end{pmatrix} - I \quad A = -Z$$

A non singular
matrix is not diag

\square

הנ"ד soft-SVM ו-hard-SVM יתנו על צ'.

$$\text{against } \frac{\lambda}{2} \|\omega\|^2 + \frac{1}{n} \sum_i \xi_i \quad \text{s.t.}$$

ω, φ_i

$$\forall i \quad \gamma_i (\omega, x_i) \geq 1 - \varphi_i \quad 1 - \varphi_i \geq 0$$

-ה גורם קשה לאחסון מושג ב-hard SVM

$$l^{\text{hard}}(\omega) = \max \{0, 1 - \omega\}$$

הנ"ד קשה לאחסון ב-hard SVM

$$\text{against } \frac{\lambda}{2} \|\omega\|^2 + \frac{1}{n} \sum_i l^{\text{hard}}(\gamma_i (\omega, x_i), \varphi_i)$$

הנ"ד מושג φ_i על מנת שפונקציית האחסון תהיה מושגת מ-0 ל-1 עבור כל i .

$$\varphi_i = \begin{cases} 0 & \gamma_i (\omega, x_i) + b \geq 1 \\ 1 - \gamma_i (\omega, x_i) + b & \text{else} \end{cases}$$

ככל רצונן בReLU כ'

$$\varphi_i = l^{\text{ReLU}}(\gamma_i (\omega, x_i) + b)$$

הנ"ד גורם קשה לאחסון מושג ב-hard SVM כ-1.01

הנ"ד מושג קשה לאחסון מושג ב-hard SVM כ-0.99

הנ"ד מושג קשה לאחסון מושג ב-hard SVM כ-0.9577 ב-hard SVM φ_i כ-0.04

.הנ"ד מושג ב-hard SVM

∴ P- \overline{f}^{∞} < 1, $f_i = 0$ $\forall i \neq 1$ (P)

$$Y_i(\langle x_i, \omega \rangle + b) \geq 1 - \delta_i \Rightarrow \geq 1 - \delta_i = 1$$

לְפָנֶיךָ יְהוָה אֱלֹהֵינוּ

$\alpha_j, \beta_j \geq 0$ per $\beta_j = 0$ se no

רְאֵת כָּלָה בְּלִיטָה וְסַדְּרָה

. A. 315-2? 45

$$\therefore \exists i, \ell_i = 1 - y_i(x_i, e) + b \quad (2)$$

$$y_i(x_i, \zeta) + b \geq 1 - (1 + y_i(x_i, \zeta) + b)$$

- P. T. S. 1981 APR B71 .-7

$y_i(\langle x_i, w \rangle + b) \leq 1$ 且 $\|x_i\|_2 = 1$

כטבנש רוכסן מילא

$$0 \leq 1 - \gamma_i \cdot (\langle x_i, w \rangle + b) = f_i$$

• $\lim_{n \rightarrow \infty} \int_{\Omega} u_n^2 dx = \int_{\Omega} u^2 dx$

ל- 80.00, מילון כ- בירור מילון ציון אל-ל'.

Topo topo topo topo topo topo topo

כטב!



ר' כרך יס ר' 2000 (ב)

Y ~ Multivariate (π)

$$x_j | y = \lambda \stackrel{iid}{\sim} N(\mu_{x_j}, \sigma_{x_j}^2)$$

בז' 2.7, 7.3.0 נגנ' נט', $x \in \mathbb{R}$ נר' נט' (ב)
7.2.8 נט' $\beta(x_i, y_i | \theta)$ פונקציית fit
פונקציית א.ב.ס.ו.מ. נט' נט' נט'

ל' 1.6.7 נט' נט' נט' נט' נט' נט' נט' נט' נט' נט'

$$\underset{\lambda \in \Lambda}{\operatorname{argmax}} \frac{f_{X|Y=\lambda}(x) f_Y(\lambda)}{f_X(x)}$$

ל' 1.6.3.ט' נט' נט' נט' נט' נט' נט' נט' נט' נט' נט'

$$\underset{\lambda \in \Lambda}{\operatorname{argmax}} f_{X|Y=\lambda}(x) f_Y(\lambda)$$

ל' 1.6.7 נט' נט' נט' נט' נט' נט' נט' נט' נט' נט'

$$L(S | X, Y) = \prod_{i=1}^n f_{X|Y=\lambda}(x_i) \cdot f_Y(\lambda) =$$

$$= \prod_{i=1}^n N(x | \mu_\lambda, \sigma_\lambda^2) \cdot \text{Mult}(\lambda | \pi) =$$

$$= \prod_{i=1}^n \frac{1}{\sum_{q_i} \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x_i - \mu_{q_i}}{\sum_{q_i}} \right)^2} \cdot \prod_{q_i} \log =$$

! $\sum_{j=1}^n p_j = 1$

$$= \log \left(\prod_{q_i} \sqrt{2\pi} \right) + \sum_{i=1}^n -\frac{1}{2} \left(\frac{x_i - \mu_{q_i}}{\sum_{q_i}} \right)^2 \cdot \log \left(\prod_{q_i} \right) =$$

$$= \sum_{i=1}^n \log(\pi_{q_i}) - \frac{1}{2} \log(2\pi) - \log(\sum_{q_i}) - \frac{1}{2} \left(\frac{x_i - \mu_{q_i}}{\sum_{q_i}} \right)^2 =$$

$$= n \log(\pi_{q_i}) - \frac{n}{2} \log(2\pi) - n \log(\sum_{q_i}) - \frac{n}{2} \sum_{q_i} \left(\frac{x_i - \mu_{q_i}}{\sum_{q_i}} \right)^2$$

$$= n (\log(\pi_{q_i}) - \log(\sum_{q_i}) - \frac{1}{2} \log(2\pi)) - \frac{n}{2} \sum_{q_i} \left(\frac{x_i - \mu_{q_i}}{\sum_{q_i}} \right)^2$$

$$= -\frac{n}{2} \log(2\pi) + \sum_{k \in [K]} -\frac{1}{2} \pi_k \log(\sum_{q_i}) - \sum_{i: q_i = k} \frac{(x_i - \mu_k)^2}{2\sum_k} + \pi_k \log(\pi_k)$$

בז' גורם לא likely good -> מילוי גורם
 גורם גודל נסיעה וטיהר וטיהר נסיעה, מוגדר
 מוגדר נסיעה וטיהר נסיעות גודל נסיעות מילוי גורם

$$\sum_{k \in [K]} \pi_k = 1 \quad \text{מילוי גורם נסיעות מילוי גורם}$$

$$g(\pi) = \sum_{k \in [K]} \pi_k - 1 = 0 \quad //$$

$$L = \lambda (\Theta | \beta e_i, g_i, \sum_{i=1}^n) - \lambda g(\pi) \quad r, \theta, \pi \in$$

Proof λ is a root of σ \Rightarrow

$$1) \frac{\frac{dL}{d\pi_k}}{\pi_k} = \frac{\alpha_k \cdot 1/\pi_k}{\pi_k} = \frac{\alpha_k}{\pi_k} \quad //$$

$\alpha_k > 0 \quad \sum \pi_k = 1$

$$\frac{dL}{d\pi_k} = \frac{\alpha_k}{\pi_k} - \lambda = 0 \Rightarrow \pi_k = \frac{\alpha_k}{\lambda} \quad //$$

$$\sum \pi_k = 1 \Rightarrow \sum \frac{\alpha_k}{\lambda} = 1 \Rightarrow \lambda = \alpha$$

$$\sum_{k \in \Sigma_L} \frac{\alpha_k}{\lambda} = 1 \Rightarrow \frac{\alpha}{\lambda} = 1 \Rightarrow \lambda = \alpha$$

$$\pi_k = \frac{\alpha_k}{\alpha} \quad //$$

$$2) \frac{\frac{dL}{d\mu_k}}{\mu_k} = \frac{1}{\mu_k} \left(- \sum_{i=1, g_i=k}^n \frac{(x_i - \mu_k)^2}{2\alpha} \right) =$$

$$= - \frac{1}{2\alpha} \cdot \sum_{i=1, g_i=k}^n (x_i - \mu_k)^2 + n\mu_k =$$

$$= \frac{1}{\sum_k} \sum_{i=1, Y_i=k}^n (x_i - \mu_k) = \frac{1}{\sum_k} \left(\left(\sum_{i=1, Y_i=k}^n x_i \right) - \theta_k \mu_k \right)$$

SEE 7.0811 0-8 2018

$$\frac{1}{\sum_k} \left(\sum_{i=1, Y_i=k}^n x_i - \theta_k \mu_k \right) = 0$$

$$\frac{1}{\sum_k} \sum_{i=1, Y_i=k}^n x_i = \mu_k \frac{\theta_k}{\sum_k}$$

$$\mu_k = \frac{1}{\theta_k} \sum_{i=1, Y_i=k}^n x_i = \underline{x}_k \quad \text{def}$$

$$3.) \frac{\frac{dL}{d\sum_k}}{\sum_k} = \frac{d}{d\sum_k} \left(-\frac{1}{2} \theta_k \cdot \log(\sum_k) - \sum_{i=1, Y_i=k}^n \frac{(x_i - \mu_k)^2}{2\sum_k} \right).$$

$$= \frac{\theta_k}{2\sum_k} + \sum_{i=1, Y_i=k}^n \frac{(x_i - \mu_k)^2}{+2\sum_k^2} = 0$$

$$\sum_{i=1, Y_i=k}^n \frac{(x_i - \mu_k)^2}{2\sum_k^2} = \frac{\theta_k}{2\sum_k} \cdot 2\sum_k^2$$

$$\sum_{i=1, Y_i=k}^n (x_i - \mu_k)^2 = \sigma_k^2 \sum_k$$

$$\Sigma_L = \frac{1}{\sigma_L^2} \sum_{i=1, Y_i=L}^n (x_i - \mu_L)^T (x_i - \mu_L) \quad \leftarrow$$

הטבות מילויים
הטבות מילויים

ונרמז על מוגן כ $\hat{\theta}_{\text{log}}$ ו $\hat{\Sigma}_L$

$$X = x_{i,j} \quad \begin{matrix} 1 \leq i \leq n \\ 1 \leq j \leq d \end{matrix}$$

$$\begin{aligned} L(\Theta | S) &= \prod_{i=1}^n N(x_{i,j} | \mu_{Y_i}, \Sigma_{Y_i}) \cdot \text{mult}(y_i | \pi) \\ &\stackrel{\text{לפ. נגזר}}{=} \prod_{i=1}^n \left(\prod_{j=1}^d N(x_{i,j} | \mu_{Y_i}, \Sigma_{Y_i}) \right) \prod_{Y_i} \pi_{Y_i} \end{aligned}$$

לפ. נגזר לוג סטט

$$\begin{aligned} \sum_{i=1}^n \left(\sum_{j=1}^d \log(N(x_{i,j} | \mu_{Y_i}, \Sigma_{Y_i})) + \log(\pi_{Y_i}) \right) \\ = -\frac{d}{2} \log(2\pi) + \sum_{k \in \{L\}} \sum_{j=1}^d \left(-\frac{1}{2} \log \log(\sigma_{Y_i, j}^2) - \right. \\ \left. - \sum_{i=1, Y_i=k}^n \frac{(x_{i,j} - \mu_{Y_i, j})^2}{\sigma_{Y_i, j}^2} + \frac{d}{2} \log(\pi_L) \right) \end{aligned}$$

برای اینجا بگوییم که λ را چگونه بخواهیم پیدا کنیم

$$L = l(\Theta | \Sigma) - \lambda g(\pi), \quad g(\pi) = \sum \pi_k - 1$$

$$\frac{\partial L}{\partial \pi_k} = \frac{1}{\sum \pi_k} \left(\sum_{j=1}^J \frac{\pi_k}{\pi_j} \log(\pi_k) \right) - \lambda = 0 \quad (1)$$

$$= \sum_{j=1}^J \frac{\pi_k}{\pi_j} \cdot \frac{1}{\pi_k} - \lambda = 0$$

$$\Rightarrow \frac{\pi_k}{\pi_k} = \lambda \Rightarrow \pi_k = \frac{\pi_k}{\lambda} \quad //$$

$$\sum_k \pi_k = 1 \quad \text{بنابراین} \quad \lambda = 1 \quad \rightarrow \quad \alpha = 1 \quad //$$

$$\pi_k = \frac{\pi_k}{1} \quad //$$

$$\mu_{k,j} \cdot \sigma \quad \text{برای } (2)$$

$$\frac{\partial L}{\partial \mu_{k,j}} = \frac{1}{\sum \pi_k} \left(- \sum_{i=1, q_i=k}^n \frac{(x_{i,j} - \mu_{k,j})^2}{2\sigma_{k,j}^2} \right) = \dots =$$

$$= \frac{1}{2\sigma_{k,j}^2} \sum_{i=1, q_i=k}^n + \lambda x_{i,j} - \lambda \mu_{k,j} =$$

$$= \frac{1}{\sigma_{k,j}^2} \sum_{i=1, q_i=k}^n x_{i,j} - \frac{\mu_k \nu_{k,j}}{\sigma_{k,j}^2} = 0$$

$$\frac{1}{\sigma_{k,j}^2} \sum_{i=1, q_i=k}^n x_{i,j} = \frac{\mu_k \nu_{k,j}}{\sigma_{k,j}^2} \quad \Leftarrow$$

$$\Rightarrow \mu_{k,j}^{\text{MLE}} = \frac{1}{n_k} \sum_{i=1, q_i=k}^n x_{i,j} \quad //$$

$$\frac{1}{\sigma_{k,j}^2} = \sqrt{(-\frac{1}{2} \lambda_k) \cdot g(\sigma_{k,j}^2) - \sum \frac{(x_{i,j} - \mu_{k,j})^2}{2\sigma_{k,j}^2}} \quad (3)$$

$$= -\frac{\lambda_k}{2\sigma_{k,j}^2} + \sum_i \frac{1}{1 + 2\sigma_{k,j}^2} \cdot (x_{i,j} - \mu_{k,j})^2 = 0$$

$$\frac{\lambda_k}{2\sigma_{k,j}^2} = \frac{1}{2\sigma_{k,j}^4} \sum_i (x_{i,j} - \mu_{k,j})^2 / \cdot \sigma_{k,j}^4$$

$$\sigma_{k,j}^2 \lambda_k = \sum_i (x_{i,j} - \mu_{k,j})^2 / \lambda_k$$

$$\sigma_{\epsilon,j}^2 = \frac{\epsilon_j}{\epsilon_k} \leq (x_{i,j} - \mu_{i,j})^2 //$$

- מילוי תבניות וריאנטים
הנחות מוגבלות כביכול γ_{k-1}
 γ_{k-2}

ת

תעלוגיה מודול פלטינום נספנת כ' רוג'ר גולד (4)

ונתן, Pois מודולר נס

$$x_{ij} \stackrel{iid}{\sim} \text{Pois}(\lambda_{k,j})$$

ונסכל likelihood \rightarrow ג'ין תל רוג'ר (א)

$$\ell(\Theta | S) = f_{X|Y|\Theta}(S) = \prod_{i=1}^n f_{X,Y|\Theta}(x_{ij}) =$$

ד. ג. ס. ב.

$$= \prod_{i=1}^n \frac{f_{X|Y=y_i}(x)}{f_Y(y_i)} =$$

$f_X(x) \sim \text{פונקציית ספטיות}$
 $P_{Y|X=x}$

$$= \prod_{i=1}^n \text{Pois}(x_i | \lambda_k) \cdot \text{mult}(y_i | \pi) =$$

$$= \prod_{i=1}^n \frac{\lambda_{k,i}^{x_i} e^{-\lambda_{k,i}}}{x_i!} \cdot \pi_{y_i} //$$

$\lambda = \mu + \sigma$
 $\lambda = \mu$

ונסכל Log סדרה \in

$$\ell(\Theta | S) = \log \left(\prod_{i=1}^n \left(\lambda_{y_i}^{x_i} \frac{e^{-\lambda_{y_i}}}{x_i!} \cdot \pi_{y_i} \right) \right) =$$

$$= \sum_{i=1}^n \left(\log \left(\lambda_{Y_i} \frac{x_i}{x_i!} e^{-\lambda_{Y_i}} \right) + \log(\pi_{Y_i}) \right) =$$

$$= \sum_{i=1}^n (\log(\lambda_{Y_i}^{x_i}) - \log(x_i!) - \lambda_{Y_i} + \log(\pi_{Y_i}))$$

$$= \sum_{i=1}^n (x_i \cdot \log(\lambda y_i) - \log(x_i!) - \lambda y_i + \log(\pi y_i)) //$$

הנומינאל גאומטריה כפלה של המרחב היא:

$$\sum_k \left(\sum_{i, \gamma_i=1} (x_i \log(\lambda_{\gamma_i}) - \log(x_i!) - \ell_k \lambda_{\gamma_i} + \ell_k \log(\Gamma_k)) \right)$$

1856-1870-1875-1880-1885-1890-1895-1900

$$g(\pi) = \sum_k \pi_k - 1$$

$$L = \ell(\theta | S) - \lambda' g(\pi)$$

$$\frac{dL}{d\pi_k} = \frac{d \left(\sum_k \pi_k \log(\pi_k) \right)}{d\pi_k} =$$

$$\text{הנ' } \pi_k = \theta_k \cdot \frac{1}{\pi_k} - \lambda' = 0 \Rightarrow \pi_k = \frac{\theta_k}{\lambda'}$$

$$\sum_k \pi_k = \sum_k \frac{\pi_k}{\lambda} = \frac{1}{\lambda} \sum_k \pi_k = 1 \Rightarrow \lambda = n$$

$$\pi_k^{\text{MLE}} = \frac{\pi_k}{n}$$

$$\frac{\partial L}{\partial \lambda_k} = \frac{1}{\lambda_k} \left(\sum_i x_i \log(\lambda_k) - \pi_k \lambda_k \right) =$$

$$= \sum_i x_i \cdot \pi_{\lambda_k} - \pi_k = 0$$

$$\lambda_k^{\text{MLE}} = \frac{1}{\pi_k} \sum_i x_i$$

MLE յիշտ ուժաւութեան դաշտում էլեկտրոնական
գրադարան

(6) כבש ועדי פורטניר ג' נס ע. מודולו צב
בצורה נורמלית

$$\begin{aligned}
 L(\Theta | S) &= \prod_{i=1}^n \left(\prod_{j=1}^d \text{Pois}(x_{ij} | \lambda_{\pi_i j}) + \log(\pi_i) \right) = \\
 \ell_{\theta} h_i &= \sum_{i=1}^n \left(\sum_{j=1}^d \log \left(\text{Pois}(x_{ij} | \lambda_{\pi_i j}) + \log(\pi_i) \right) = \right. \\
 &= \sum_{i=1}^n \left(\sum_{j=1}^d \log \left(\frac{\lambda_{\pi_i j}^{x_{ij}} \cdot e^{-\lambda_{\pi_i j}}}{x_{ij}!} \right) + \log(\pi_i) \right) = \\
 &= \sum_i \left(\sum_j (x_{ij} \cdot \log(\lambda_{\pi_i j}) - \log(x_{ij}!) - \lambda_{\pi_i j}) + \log(\pi_i) \right) = \\
 \gamma_{\lambda, \sigma} &= \sum_{k \in K} \left(\sum_j \left(\sum_i (x_{ij} \log(\lambda_k) - \log(x_{ij}!) \right) - \right. \\
 &\quad \left. - \pi_k \lambda_{\pi_i j} + h_k \log(\pi_k) \right) \quad \text{||}
 \end{aligned}$$

הכל זו $\mathcal{L}(\theta)$ גורגן יד, אנו מעתה בקשר למשתנים

$$\hat{\pi}_k = \frac{\pi_k}{\sum_k} \quad \text{כגון בפער ב-1}$$

$$\frac{\partial \mathcal{L}}{\partial \lambda_{\pi_i j}} = \frac{1}{\lambda_{\pi_i j}} \left(\sum_j \left(\sum_i (x_{ij} \log(\lambda_{\pi_i j}) - \lambda_{\pi_i j}) \right) \right)^{(2)}$$

$$- \sum_j \left(\left| \frac{x_{i,j}}{\lambda_{k,j}} \right| - \ell_k \right) \rightarrow \begin{matrix} 11.2 & 1.7 \\ 0.02 & 1.7 \\ 12.1 & 1.7 \\ 1.7 & 12.1 \\ 12.1 & 1.7 \\ 1.7 & 12.1 \end{matrix}$$

$$- \sum_i \frac{x_{i,j}}{\lambda_{k,j}} - \ell_k = c$$


$$\lambda_{k,j}^{\text{MLE}} = \frac{1}{\ell_k} \cdot \sum_{i: x_{i,j}=k} x_{i,j}$$

Praktisch ein numerisches Problem werden kann \Leftrightarrow
! Null, falls alle $x_{i,j} = 0$

↗


Perceptron Classifier

.1. להלן גראף הפלט עבור סט האימון שmorphd ליניארית



ניתן ללמידה מפלט זה כי במקרה של דאטה המפורד ליניארית, אלגוריתם מצליח למצוא את העל מישור המפריד, יחסית בקלות. קרי לאחר 52 איטרציות, האלגוריתם עוזר מכיוון שהוא הצליח למצוא על מישור מפריד בעל ERM אפס תחת סט אימון זה.

.2. להלן גראף הפלט במקרה הלא מופרד.




עבור מידע זה נוכל לראות כי ה-Perceptron לא מצליח לעצור. זאת מכיוון שהמידע לא מופרד, אז כל תיקו בעצם פוגע בתיקון הקודם – لكن הניתן לראות כי האלגוריתם נתקע בולאה אינסופית עד שהוא מגיע לכמויות האיטרציות שהגדנו לו.

ניתן לראות כי השוני מהשאלה הראשונה נובע מכך שעבור מידע מופרד ליניארי, האלגוריתם פועל אך אחרת לא נוכל ללמידה מידע זה ע"י שימוש *perceptron*.

Bayes Classifiers


1. להלן הפלטים עבור סט הנתונים הראשון:



מניתוח הפלט ניתן לראות כי האלגוריתמים השונים הצלicho לחזות בצורה טובה דआטא שחולק ל-3 מחלקות שונות, כאשר אלגוריתם *naive bayes* מצליח לחזות בצורה טובה יותר, מכיוון שהוא מיציר מטריצת שונות לכל מחלוקת, ובמקרה בו המידע מופרד באופן זה הניל' אפשר לנוט לחזות טוב יותר.

כמו כן, ניתן ללמידה כי ככל שהאליפסה שנוצרת ע"י מטריצת השונות מכסה יותר מן הדגימות, אז האלגוריתם מצליח לחזות בצורה טובה יותר את הדאטה – הניל' נובע מן העבודה בכל הגaosיאן עשינו לו *fit* מתחקה בצורה טובה יותר להתפלגות המקור ולכן המודלים שלנו המבוססים על התפלגות זו מתפקדים בצורה טובה.

2. להלן הפלטים עבור הסט המידע השני.



ניתן לראות כי תחת סט האימון הנ"ל *naive bayes* מתקשה לחזות ביחס לאילו-*LDA*, הנ"ל נובע לכך שניתן להבין כי ככל'ן המידע שקיבלו תלוי ליניארית זאת בניגוד להנחה העבודה שאנו מאמצים בעת העבודה עם מודל *naive bayes* (הצדקה לכך ניתן לראות גם בנסיבות הדטה). לכן, הנ"ל מתקשה לחזות את המידע וממצא מטריצות שונות מתאימות לכל מחלקה (בניגוד למקרה הקודם, שההפרדה הקללה אפשרה בחירת שונות ש抬头יה עם הפרדיקציה). זאת מנגד לפעולת *LDA* שאינה מניחה דבר זה ועל כן היא מצליחה לחזות בצורה טובה את המידע.

טעוון זה ניתן לחיזוק ע"י שימוש במטריצות השונות, ה-*LDA* מחשב את השונות על כל הדטאא ללא קשר למחלקה, דבר שמתפרק באופן יותר טוב אחר הדטאא (כפי שאנו רואים בתרגול) בניגוד ל-*naive bayes*-*LDA* אשר מייצר מטריצות שונות לכל מחלקה אשר אינם מכוסות בצורה טובה את התפלגות הדטאא – ועל כן דיוקו ירד.