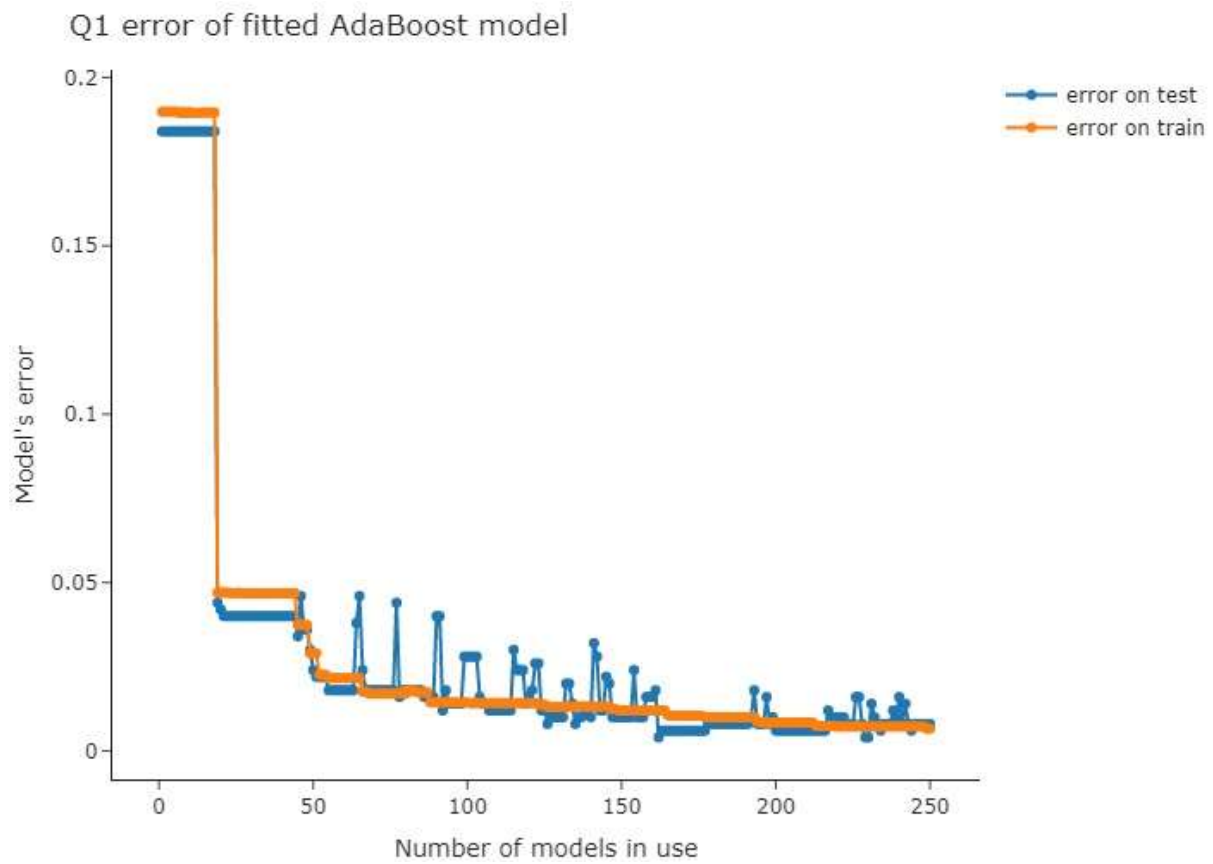


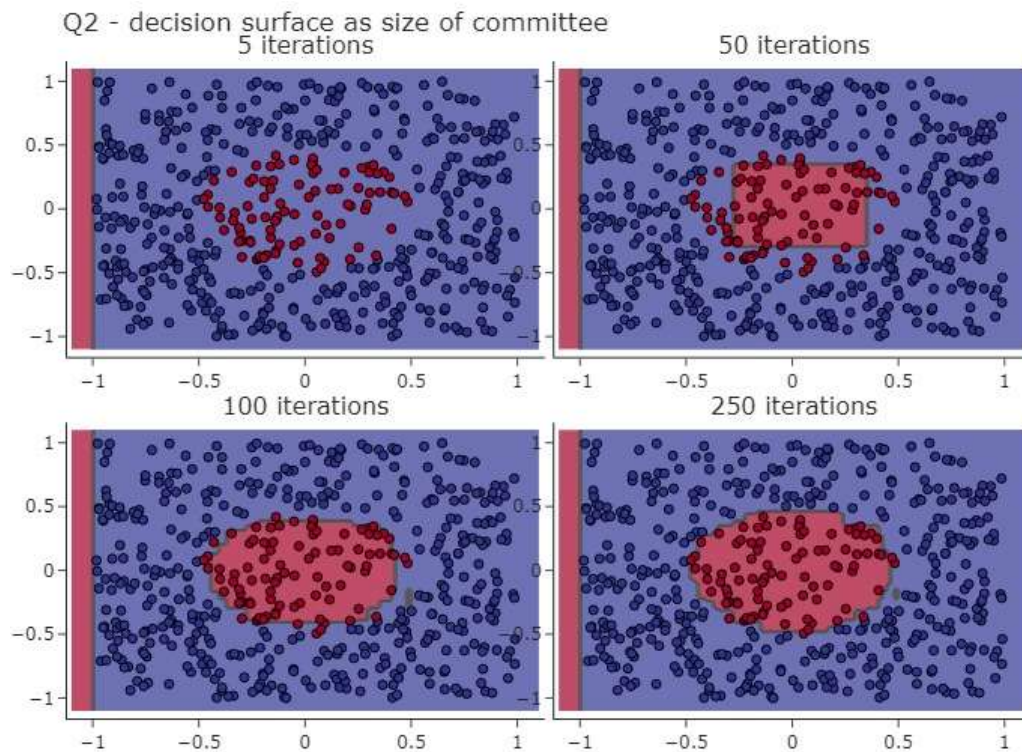
1. להלן פלט השגיאות של המודל



נתבונן בתוצאות הפלט, ניתן לראות כי על סט כאשר אנו עוברים סף מסוים של מודלים, השגיאה שלנו שואפת ל-0 – דבר שנצפה לראות תוך שאנו מאמינים לנכונות המודל והיכולת שלו לחזות להתחקות אחרי סט האימון.

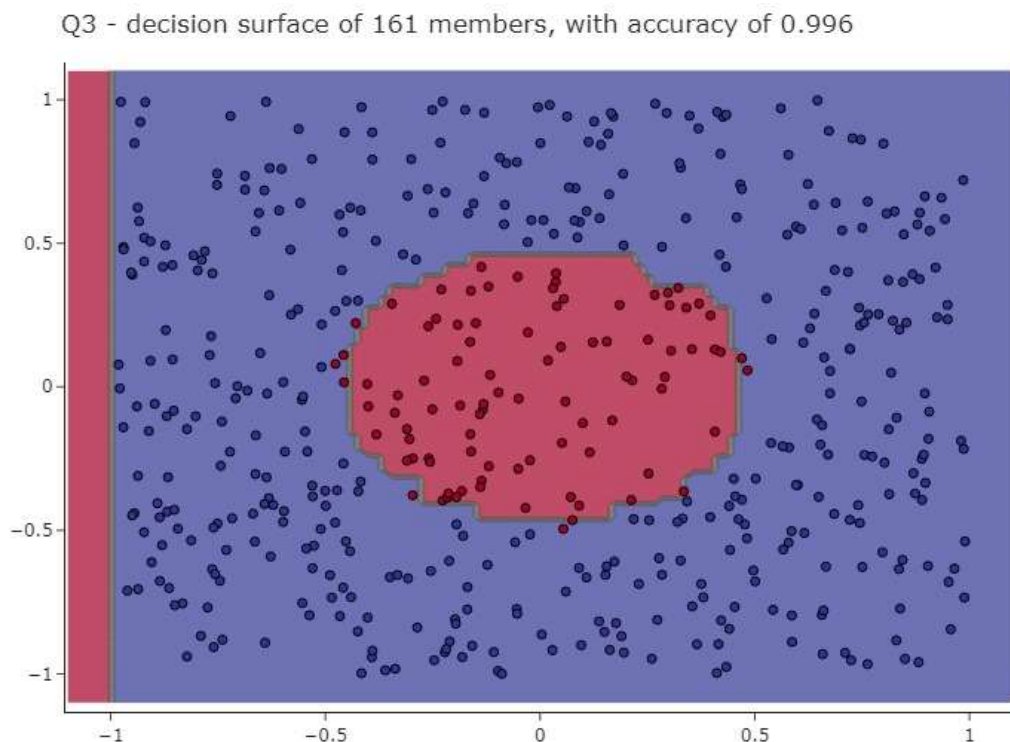
כמו כן, אם נתבונן הכחול, המייצג את השגיאה על סט הבדיקה – ניתן לראות כי קיימת מגמת שאיפה ל-0 קרי המודל שלנו מצליח כ"כ שמספר חברי הועדה גדול לחזות בצורה טובה את הדאטא שהתקבל, תוך שאנו מזהים קפיצות בשגיאה כתלות בחברי הועדה. דבר זה מלמד אותנו כי עבור מודלים המתבססים על אנסמבל של מודלים – עלינו תמיד לבצע דיוק של מספר חברי הועדה ולא לקחת את המספר הגדול ביותר.

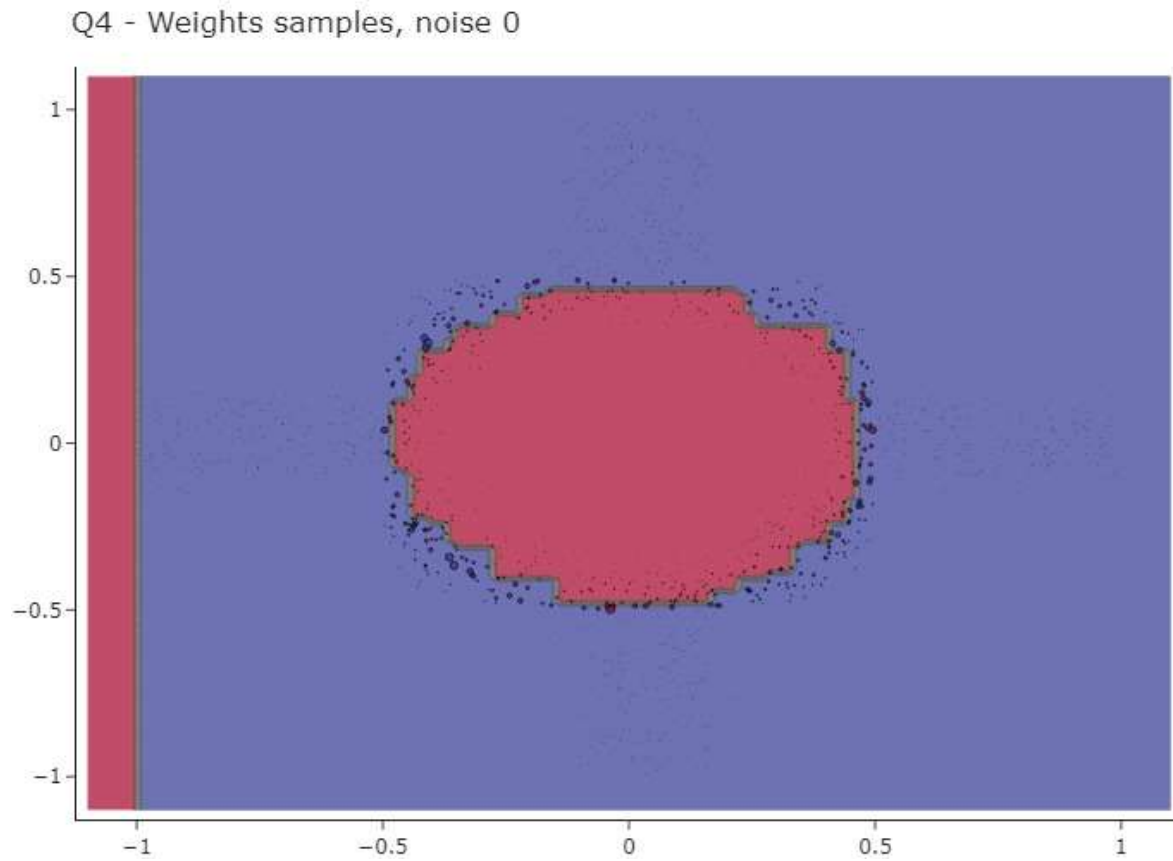
2.



בפלט זה ניתן לראות את יכולת החיזוי של המודל שלנו כתלות במספר המודלים. כפי שראינו גם בשאלה 1, קיימת מגמת שפר משמעותית כ"כ שהמספר עולה, תוך דיוק שנדרש על המספר המדויק. דבר זה נראה גם כאן, כ"כ שהשגיאה של המודל יורדת – מישור ההחלטה שלנו מתאים את עצמו טוב יותר לסט הבדיקה שקיבלנו דבר שניתן לראות באופן ישיר בפלט הנ"ל.

3. מצ"ב הפלט.






אילו נתבונן בפלט זה ניתן לראות בבירור את הדגימות שעליהם המודל שם דגש כפונקציה של גודל הנקודה. נזכר כיצד אלגור' ה-*AdaBoost* עובד – אנו ניתן משקל גבוהה למשקולות לדגימות שעד כה נובאו בצורה לא טובה ונרצה שהמודל ייקח אותם בחשבון באימון המודל החדש.


דבר זה בא לידי ביטוי גם בפלט זה, גודל הדגימה הוא הקושי של המודל לחזות אותה וכ"כ שזו יותר גדולה, כך המשקל שניתן לה גדול יותר. נקודות קטנות אינן מקבלות משקל גבוהה מכיוון שהמודל הצליח לחזות אותן בהצלחה, אך ניתן לראות כי גם מחוץ למישור ההחלטה קיימות נקודות אדומות גדולות – אלו נקודות שהמודל נכשל בהן ונתן להם משקל גבוהה כדי שאיטרצית האימון הבאה תיקח אותם בחשבון. אילו הדגימות שמאתגרות את המודל ובעצם מהוות את הרעיון מאוחרי ביצוע ה-*boosting*.

5. להלן הפלטים כאשר שנינו את הרעש ל-0.4

Q1 error of fitted AdaBoost model



Q4 - Weights samples, noise 0.4



נשים לב כי דיוק המודל כעת לא מתכנס עוד ל-0 אלא שואף למספר הקרוב לרמת הרעש – תוצאה הגיונית שנצפה לה, מכיוון שזהו הדיוק שנוכל לצפות כאשר הרעש כה גבוהה. כמו כן, בניגוד לסט האימון שטעות המודל יחסית קונסיסטנטית, ניתן לראות כי עבור סט הבדיקה הגרף בעל קפיצות גדולות !

דבר זה מצביע בדיוק על עיקרון *bias – variance tradeoff*, הלומד שלנו מנסה ללמוד מידע מאוד רועש, כאשר בכל איטרציה אנו נותנים לו יותר ויותר משקל – דבר שמעלה את ה-*variance* של המודל וגורם לו להיות הרבה יותר רגיש לשגיאות רועשות כפי שראינו עד כה בקורס. נשים לב כי עדין ישנם ועדות שמצליחות לתפקד בצורה טובה על בדיקה – דבר שמחזק את הצורך בביצוע דיוק סופי בבניית מודלי *boosting*.

נשים לב כי תופעה שהצגתי מעלה גם מגולמת בגרף השני, אנו רואים כי המודל מתקשה בחיזוי ונותן משקל רב להרבה דגימות, קרי אנו רואים המון נקודות אדומות וכחולות גדולות מפוזרות ע"ג המישור, כאשר מישור ההחלטה מנסה להתחקות אחרי חלק מהן. כנראה שבמקרה זה כאשר נגדיל את מספר המודלים ונמשיך לפעול בצורה הממושקלת הנ"ל נצליח להתמודד גם בצורה טובה יותר עם מידע רועש מסוג זה.