

מבוא למכניקת קוונטים
 חלק 1: מכניקת קוונטים
 תרגיל 5 - תרגילי הבית

Regularization (1) יהי $x \in \mathbb{R}^{n \times d}$ ו- $y \in \mathbb{R}^d$
 ונניח כי $x^T x$ הפכה.

אם $\lambda > 0$ אז $x^T x + \lambda I$ הפכה.
 1 - w_λ^T הוא נורמן Ridge (כאשר $\lambda = 0$ $w_\lambda^T = w^T$)

(2) נראה כי $w_\lambda^T = A_\lambda w^T$ כאשר $A_\lambda = (x^T x + \lambda I)^{-1} (x^T x)$
 פתרון: בדואים עליו כי

$$w_\lambda^T = (x^T x + \lambda I)^{-1} x^T y$$

באופן נוסף כי $w^T = x^T y = V \Sigma^T U^T y$, U, V הם אורתוגונליים

$$X = U \Sigma V^T \quad \text{נציב}$$

$$A_\lambda w^T = (x^T x + \lambda I)^{-1} (x^T x) w^T =$$

$$= (x^T x + \lambda I) \cdot (U \Sigma^T U^T U \Sigma V^T U \Sigma^T U^T y)$$

נרצה להפוך את $x^T x$ ל- $x^T x + \lambda I$!
 נרצה להפוך את $x^T x$ ל- $x^T x + \lambda I$!

$$\Sigma_{i,i}^+ = \begin{cases} 1/a_i & a_i \neq 0 \\ 0 & \text{p.l.s.p} \end{cases} \quad \text{כאשר } a_i \neq 0$$

$$\Sigma_{i,i} = \sigma_i$$

$$\Sigma \Sigma^+ = \begin{cases} 1 & \sigma_i \neq 0 \\ 0 & \text{p.l.s.p} \end{cases} \quad \Leftarrow$$

לכן $X^T X$ הפכה, Σ הוא כמות המגדירה את $X^T X$ ו- Σ^+ הוא הפוך של Σ (p.l.s.p) ו- $\Sigma \Sigma^+ = I$!

$$\Sigma_{i,i}^+ = 1/\sigma_i \quad \Leftarrow$$

$$\Sigma \Sigma^+ = I$$

$$\Rightarrow (U \Sigma^T U^T \cancel{U \Sigma V^T U \Sigma^+ U^T} Y) = X^T Y$$

$$A_\lambda \hat{w} = (X^T X + \lambda I)^{-1} X^T Y = \hat{w}_\lambda \quad \Leftarrow$$

פירוק!

(6) נראה כי $E(\hat{w}_\lambda) \neq w$ כאשר $\lambda > 0$

$$E(\hat{w}_\lambda) \neq w \quad \lambda > 0$$

נניח:

$$E[\hat{w}_\lambda] = E(A_\lambda \hat{w}) = E((X^T X + \lambda I)^{-1} X^T X \hat{w})$$

$$(X^T X + \lambda I)^{-1} X^T X \cdot E(\hat{w}) \neq w$$

כלומר $E(\hat{w}) \neq w$ כאשר $\lambda > 0$

נכיון - ל סדר $(X^T X + \lambda I)^{-1}$ ויש להם תכונה של
 $X^T X$, λ קטן, כלומר λ קטן, λ קטן
 $\omega_1^T \neq \omega$ אם

(c) נראה כי ω_1^T אינו:

$$\text{var}(\omega_1^T) = \text{var}(A_\lambda \omega^T) =$$

בגודל
 λ קטן

$$= A_\lambda \text{var}(\omega^T) A_\lambda^T = A_\lambda \cdot \sigma^2 (X^T X)^{-1} A_\lambda^T$$

$$= \sigma^2 A_\lambda (X^T X)^{-1} A_\lambda^T$$

(d) נסתכל בביטוי למעלה. Bias-variance כפונקציה של λ .

נראה: במידה ו λ קטן, כי

$$\text{MSE} = E[\|\hat{\gamma} - \gamma\|^2] = \text{Bias}(\hat{\gamma})^2 + \text{var}(\hat{\gamma})$$

$$\text{MSE} = \text{Bias}(\omega_\lambda^T)^2 + \text{var}(\omega_\lambda^T) =$$

$$= E[\omega_\lambda^T]^2 + \sigma^2 A_\lambda (X^T X)^{-1} A_\lambda^T =$$

$$E[A_\lambda \omega^T] = A_\lambda E(\omega^T) = A_\lambda \omega$$

$$\frac{d}{d\lambda} \text{Var}(w_1) = \sigma^2 \frac{d}{d\lambda} \text{tr} (A_\lambda X^T X A_\lambda^T)$$

המטריצה $X^T X$ היא מטריצה סימטרית
 והמטריצה A_λ היא מטריצה סימטרית

$$\frac{d}{d\lambda} \text{Var}(w_1) = \sum_{i,j} \frac{d \text{Var}(w_1)}{d(A_\lambda)_{i,j}} \cdot \frac{d(A_\lambda)_{i,j}}{d\lambda} \Big|_{\lambda=0}$$

$$= \text{tr} \left(\frac{d \text{Var}(w_1)}{d A_\lambda} \cdot \frac{d A_\lambda}{d \lambda} \right) \Big|_{\lambda=0}$$

$$= -2\sigma^2 \text{tr} \left((X^T X)^{-1} (X^T X)^{-1} \right) < 0 //$$

= קיבלנו כי המידת ה- $\text{tr}(F)$ היא $-1/\sigma^2$, נכפיל!

אז

(f) נסיק מן היות כי עבור גליל הנמצא אצל λ מילימטר
 קחי מילימטר ה- λ ובהקרה זה $\lambda = 1$ ונרצה, מה
 שאמר כי המספר קטן.

= מכך קיבלנו כי גם בהקרה בה $\lambda = 1$, קחי
 זהו מובא על סמך, אנו מודעים כי המידת
 מילימטר = המילימטר.

מכיוון שהפונקציה רצופה (אין שגיאות) בגשר ג'ס
אך עדין קיין מאד נקט כי עדין ה-MSE קיין
= הוסבר עדין יאופניצית קידור Ridge קיין
אך ה-MSE כנראה!

PCA

(2) נתון: נמצא כיוון המרחב החד-ממדי המקסימלי של התבוננות על המרחב \mathbb{R}^d ו- $v^T x$ הוא המרחב החד-ממדי המקסימלי של התבוננות על המרחב \mathbb{R}^d .

כך: $\|v\|_2 = 1, v \in \mathbb{R}^d$ ה.

$$E(v^T x) = \frac{1}{n} \sum_{i=1}^n v^T x_i \approx \text{ממוצע} \\ = v^T \bar{x} \quad \text{נראה כי}$$

$$\text{var}(v^T x) = E_x((v^T x_i - E_x[v^T x])^2) =$$

$$= \frac{1}{n} \sum_i (v^T x_i - v^T \bar{x})^2 =$$

$$= \frac{1}{n} \sum_i [v^T (x_i - \bar{x})]^2 =$$

$$= \frac{1}{n} \sum_i (v^T (x_i - \bar{x})) (v^T (x_i - \bar{x}))^T =$$

$$= \frac{1}{n} \sum_i v^T (x_i - \bar{x}) (x_i - \bar{x})^T v =$$

$$= v^T \underbrace{\sum_i (x_i - \bar{x}) (x_i - \bar{x})^T}_{\text{COV Sample set}} v =$$

$$= v^T S v$$

$$\hat{v} = \underset{\|v\|=1}{\text{argmax}} v^T S v$$

לכיוון המרחב המקסימלי

lagrange multiplies - 2 rsh

$$\eta(V) = 1 - \underset{V}{V^+ V} \quad \text{r. 2d)}$$

$$L = v^T v + \lambda g(v)$$

$$\frac{d}{dv} L = 25v - 21v = 0$$

$\vec{u}^T V$ & $\vec{u}^T V^T$

ניחן סבסג כי ^לאגג פוגג חוג א' ח' עסג
באגג!

\Rightarrow קיבלנו כי ההצבה $z = 1$, $w = 1$ היא פתרון של המערכת
 $z = 1$, $w = 1$ היא הפתרון הכללי של המערכת
 $x = 1$, $y = 1$

IV

הצגה

(3) ה. ל. הקנה פונקציה, f כ. f פונקציה

$$\tilde{K}(x, x') = f(x) \cdot k(x, x') \cdot f(x')$$

ה. ל. PSO פונקציה

$$f(x) \cdot \begin{cases} \frac{1}{\sqrt{k(x, x)}} & k(x, x) \geq 0 \\ -\frac{1}{\sqrt{-k(x, x)}} & \text{else} \end{cases}$$

$\therefore \text{ה. ל. } \text{פונקציה}$

$$\begin{aligned} \tilde{K}(x, x) &= f(x) k(x, x) \cdot f(x) = & k(x, x) \geq 0 \\ &= \frac{1}{k(x, x)} k(x, x) = 1 // \end{aligned}$$

$k(x, x) < 0$ פונקציה

$$k(x, x) = \frac{1}{\sqrt{-k(x, x)}} k(x, x) \cdot \frac{1}{\sqrt{-k(x, x)}} = 1 //$$

ה. ל. פונקציה

121

4. נכונה \exists כ"ף: $\mathbb{R}^2 \ni x$ כאשר $x_i = (x_i, y_i)$
 נקודת סגור ונקודה ב-המשאל וכן יחס

כאן הבל:

מ $\sqrt{x_i^2 + y_i^2}$ זאי לני נחזיר 1 זח

-1.

\Rightarrow וזי עב כי עא ויקן ערפיר לר 6
 הלינו כ- \mathbb{R}^2 כאן לני.

לדיר $\psi(x) = (x_i, y_i, \sqrt{x_i^2 + y_i^2})$

\Rightarrow נוסף לנג מליצ"ל מ זוליור הלינד

כאן זה נוסף עזא יפחה פדעזל כאשר

ולה לנג ע"י מלל מ פל לעל גפרי

לחזר!

5. (a) φ is a homomorphism from G to H .
 (b) φ is a homomorphism from G to H .

۱۷

$$S = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \rightarrow \underline{\text{Hermitian}}$$

$$k = e^{-\frac{1}{2}\|x-y\|^2}$$

$$K = \begin{pmatrix} 1 & e^2 \\ e^2 & 1 \end{pmatrix}$$

$v = \begin{pmatrix} -2 \\ 1 \end{pmatrix}$, PSD u \perp v , $u = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$

$$V^T U = (2 + e^2 \quad -2e^2 + 1) \begin{pmatrix} -2 \\ 1 \end{pmatrix} =$$

$$-7(-2+p^2) - 2p^2 + 1 = 4 - 4p^2 + 1 = 5 - 4p^2$$

$$t \sigma_L \leq 5 - 4 \rho^2 < 0 \quad \Leftrightarrow \quad \rho^2 > 2 \in$$

10710, P50

𐤁𐤏𐤃

(6) $\sqrt{f} \in \mathcal{O}$ and $f(x, x) = 0$ for all $x \in \mathcal{O}$.

נבחר לנ קהילה פועל נועם יאיר כס לזל

ۛۛۛۛۛۛ

$$k_1(x, z) = (c(x, z) + -5)^3$$

$$h_2(x, z) = (\langle x, z \rangle + 0)^2$$

11

$$\lambda(0,0) = \lambda_1(0,0) - \lambda_2(0,0) = -5^3 =$$

$\sum \dot{m} = -25 \text{ L}$

五

(C) 1977 by J. K. J. J.

2.2.5. $P_{\delta\gamma\gamma}$ k_a, k_b 1.7. הכנסות

في ١٩٨٢ في ١٩٨١ $K = K_a + K_b$

$$x = \begin{bmatrix} \underline{x_a} \\ x_b \end{bmatrix} \quad x \in \mathbb{R}^d - 1$$

$$k_{ij} = k_{a_{ij}} + k_{b_{ij}} \quad \text{כאשר } \underline{p.17}$$

! 7.75.0 5, 15, 25

1727. 1728. 1729. 1730.

$$K(x, x) = x K x^T = x (K_a + K_b) x^T$$

מאמץ כ. ג' קיים בן גורג מאמץ כללר כמות
הקצאות על ת.ס.א. א.א.א.

$$X = X_a + X_b$$

השאלות
שנשאלו
אובבליסטר
הם אנשים
על.

$$X / c X^T = (x_a^* + x_b^*) / c (x_a^* + x_b^*)^T =$$

$$= x_a^* k x_a^T + x_b^* k x_b^T =$$

$$= X_a^* (K_a + K_b) X_a^{*T} + X_b^* (K_a + K_b) X_b^{*T}$$

= גמלורה ה קרעז חרדי' אסטאין יק א
ה קורדי. נאע ארעמואל' אדער נאן עיק א

$$\Rightarrow x_a^* k_a k_a^* + 0 + 0 + x_b^* k_b k_b^* =$$


$$= x_a^T K_a x_a + x_b^T K_b x_b \geq 0$$

Pool - D
C
J
K
L
M


ע' א' ס' 1950 י' ס' 1971!

1. להלן הפלטים עבור סט הנתונים בהינתן קלטים שונים


Q1, noise = 5, n=100



Q1, noise = 0, n=100




Q1, noise = 10, n=1500




2. להלן הפלטים בהינתן התרחישים השונים (תושבה משולבת עבור סעיפים 4,5):


Q2, noise = 5, n=100



Q2, noise = 0, n=100



Q2, noise = 10, n=1500





נתבונן בתוצאות שקיבלנו, נשים לב למספר אבחנות:

- ראשית כאשר כמעט ואין רעש שגיאת האימון מתלכדת עם שגיאת הולידאציה – אבחנה שנובעת ישירות מן העבודה כי כל הנקודות מייצגות את המציאות, כאשר אין משמעות אמיתית לאימון המודל על חלקים שונים (רועשים יותר או פחות) – כאשר הרעש עולה ההפך מתקבל, שוב אבחנה לה אנו מצפים.
- כמו כן, מנגנון הבקרה שלנו עובד כאשר ניתן לראות כי שגיאת הולידאציה גדולה לרוב משגיאת הסט האימון – כמו כן דבר שנרצה לראות.
- נשים לב כי תחת שינוי דרגות הפולינום השגיאות גם מתנהגות בצורה קוהרנטית, כאשר שדרגת הפולינום מתקרבת לדרגה האמיתית השגיאות הן מזעריות ביחס לקצוות האחרים – נשים לב כי שתי המדידות מקיימות גם את עיקרון *bias* – *variance* שראינו מספר פעמים עד כה בקורס (*under fit* מול *overfit*).
- לבסוף נראה כי גם כאשר אנו מעלים את מספר המדידות שלנו למרות שהרעש גדול, המודל מצליח להתמודד ולספק תחזית טובה. זאת אנו מסוגלים להפיק תחת שימוש ב-*cross validation*, בכל שלב מבצעים אימון על חלק אחר בסט האימון שלנו ובודקים שוב ושוב כך שהמודל נחשף לכמה שיותר מן המידע. באופן זה אנו מקטינים את ה-*overfit* שיכול להתקיים בהתאמת פולינומים תחת רעש גבוהה ומחזקים את השימוש בחוק המספרים הגדולים – שגם תחת הרעש מספר רב של דגימות ישאף לתצורה האמיתית (נשאף לתוחלת, אשר 0) ולכן נוכל עדין לקבל פרדיקציה טובה.

3. להלן דרגות הפולינום אשר המודל חזה עם הטעויות שקיבלנו עבור שימוש בדרגה זו:

- במקרה עבור 100 דגימות ורעש 5 - $k = 4, MSE = 16.57$
- במקרה עבור 100 דגימות ורעש 0 - $k = 5, MSE = 1.35$
- במקרה עבור 1500 דגימות ורעש 10 - $k = 4, MSE = 98.89$

7. להלן הפלטים עבור $\lambda \in [0,1]$ אשר נלקחו 500 נקודות במרחק שווה. אציין כי ע"מ להגיע לטווח זה, ראשית התחלתי עם טווח גדול $[0,10]$ ניתן היה לראות כי השגיאה מתקבעת ב- ~ 4 ולכן צמצמתי את הטווח עד לקבלת מדידה שאפשרה לקבל ערך מינימלי.



שוב ניתן לראות את הבדל הניכר בין השגיאות על סט האימון וסט הוואלידציה, כאשר הפער היה מעט גדול יותר עבור השימוש ב-*Ridge*. כמו כן, ניתן לראות את מגמת השגיאה כמגמה שראינו

בכיתה – לפיה השימוש בנורה l_2 מייצרת פונקציה גזירה ב-0 ולכן עקומת רידג' מעט מזכירה יותר פרבולה מאשר עקומת $Lasso$ אשר דומה יותר לפונקצית הערך המוחלט.

כמו כן, ניתן לראות כי הוספת ערך הרגולריזציה השפיע יותר בהתחלה על $Lasso$ מאשר על $Ridge$ ביכולת להוריד את השגיאה תחת סט הולידאציה.

8. להלן תוצאות השגיאה שהתקבלו עבור שלושת המודלים :

Ridge achieved 3249.69 with lambda of 0.024

Lasso achieved 3641.16 with lambda of 0.597

Basic linear regression achieved 3612.25

ניתן לראות כי במקרה זה $Ridge$ הוא זה שהשיג את השגיאה הקטנה ביותר, תחת שימוש בפרמטר רגולריזציה מאוד קטן, כ-0.02 אך על סט האימון הקטן הנ"ל גרר שיפור משמעותי (מעל 10%) בשגיאה.